

RAPPORT ECONOMETRIE

QUELS SONT LES DETERMINANTS MICROECONOMIQUES DE
LA FORMATION DES PRIX SUR LE MARCHE INTERIEUR
AMERICAIN DU TRANSPORT AERIEN ?

Moriceau Rémi
Combe Enzo
Boukharaze
Julien

INTRODUCTION.....	2
I – BASE DE DONNEES ET TENDANCES	3
MODELE PANEL/COUPE TRANSVERSALE.....	3
TABLEAU DES STATISTIQUES DESCRIPTIVES.....	5
EQUATION A ESTIMER	6
NOS INTUITIONS DE DEPART	6
EQUATION ESTIMER.....	6
II - DETECTION DE L'HETEROSCEDASTICITE DANS LE MODELE	8
TEST DE WHITE	9
TEST DE BREUSCH-PAGAN	10
MODELE ROBUSTE	11
III – TEST.....	11
TEST DE STUDENT.....	12
TEST DE FISCHER	12
QUALITE D'AJUSTEMENT DU MODELE	12
POINT MOYEN DE L'ECHANTILLON	13
IV - HYPOTHESES POTENTIELLEMENT NON RESPECTEES	14
V - LIMITE DE LA BASE DE DONNEES	15
L'ABSENCE DE LA DATE DE RESERVATION.....	15
L'ABSENCE DE DISTINCTION DE CLASSE ET QUALITE DU SERVICE.....	15
COUTS AEROPORTUAIRES ET CRENEAUX HORAIRES.....	15
VI – CONCLUSION.....	16
VII - BIBLIOGRAPHIE	16

Introduction

Le transport aérien est un pilier de l'économie américaine. L'aviation permet de connecter les différentes métropoles d'un si grand pays, notamment pour des déplacements professionnels et le tourisme, qui sont les principales raisons.

D'après la FAA (*Federal Aviation Administration*), plus de 3 millions de passagers circulent quotidiennement dans l'espace aérien américain. L'aviation est un service connu pour sa forte volatilité des prix, même lors de stabilité économique. Cette volatilité s'explique par une stratégie de tarifications dynamiques (ou *Yield Management*) utilisée par les compagnies dans le but de maximiser leur revenu. Il s'agit d'une forme de discrimination par les prix car deux passagers peuvent payer des prix très différents pour le même vol. Pourtant, on trouve peu d'informations expliquant pourquoi le prix varie autant d'un vol à l'autre, et quels sont les facteurs précis qui composent ce tarif final pour le consommateur. Ce flou rend le sujet d'actualité, notamment vis-à-vis des questions de pouvoir d'achat et de concurrence.

La majorité des médias s'intéresse au prix du pétrole et à ses répercussions sur les prix des compagnies aériennes. L'augmentation des coûts fixes, la régulation ainsi que les normes ont fortement évolué, ce qui donne suite à des changements dans les stratégies tarifaires, impactant ainsi le marché global et entraînant des effets macroéconomiques.

Il est plus rare de trouver des informations microéconomiques qui expliquent les variations de prix des billets, qui ne prennent pas seulement en compte la distance ou le temps. C'est donc pour cela que nous avons abordé la problématique suivante : « Quels sont les déterminants microéconomiques de la formation des prix sur le marché intérieur américain du transport aérien ? »

Nous nous questionnerons donc sur les facteurs pouvant influencer le prix individuel d'un billet.

Pour cela, nous utiliserons la base de données AIRFARE de Gretl (au sein du livre *Introductory Econometrics* de Wooldridge).

Dans un premier temps, nous expliquerons notre base de données ainsi que ses tendances. Deuxièmement, nous détaillerons le choix du modèle sélectionné ainsi que les tests réalisés. Puis, dans une troisième et dernière partie, nous aborderons les différentes théories et les suppositions émises par d'autres modèles, ainsi que les limites rencontrées tout au long de notre rapport.


I – Base de données et tendances

Modèle panel/coupe transversale


La base de données AIRFARE porte sur l'observation des tarifs aériens. Au total, il y a 4 596 observations sur 4 années (1997 à 2000), il s'agit donc d'un panel. Nous allons seulement voir l'année 2000, donc nous allons travailler sur 1 149 observations, ce qui transforme notre base de données en coupe transversale.

Le prix des billets d'avion est expliqué par différentes variables quantitatives, comme la distance, le nombre moyen de passagers et la part de marché détenue par la compagnie dominante. Mesurées en miles, le nombre de passagers et la concurrence sont compris entre 0 et 1 (0 % et 100 %).

fare vs dist (avec ajustement MCO)



fare vs concen (avec ajustement MCO)






Figure 1 : Nuage de points des variables explicatives

Les graphiques de la figure 1 représentent le nuage de points des variables explicatives par rapport au prix. On remarque une relation croissante avec la distance et la concentration, et décroissante pour la demande. Le prix du billet, en dollars, est expliqué par différentes variables quantitatives comme la distance mesurée en miles, la demande (nombre moyen de passagers) et la concentration du marché (part de marché du leader).

	Moyenne	Médiane	E.T.	Min	Max
dist	989,74	861,00	612,03	95,000	2724,0
passen	670,91	378,00	847,34	2,0000	8497,0
fare	188,02	178,00	76,842	62,000	522,00
concen	0,60157	0,58720	0,19702	0,17970	1,0000

1 : Statistiques descriptives (Source : Gretl)

Tableau des statistiques descriptives

Les statistiques descriptives permettent de nous donner un premier aperçu des observations sur le prix des billets. La concentration (*concen*) prend des valeurs comprises entre 0 et 1 (s'expliquant par son unité en part de marché).

À l'inverse, la distance (*dist*) et le prix (*fare*) présentent de grands écarts-types, montrant la diversité des vols. C'est d'ailleurs l'une des raisons qui nous poussera à transformer ces deux variables par le logarithme.

Cette spécification nous permet de réduire l'impact des valeurs extrêmes et de stabiliser la variance, mais aussi d'interpréter directement les coefficients de la distance en termes d'élasticités, tout en conservant la concentration en niveau.

Equation à estimer

$$\log(fare_i) = \beta_0 + \beta_1 \log(dist_i) + \beta_2 \log(dist_i)^2 + \beta_3 \log(concen_i) + \beta_4 \log(passen_i) + u_i$$

L'équation à estimer est une log-log. Nous cherchons à expliquer la variation du prix des billets d'avion en dollars en fonction de :

- β_1 représente la log distance exprimée en miles
- β_2 représente la log distance au carré exprimée en miles
- β_3 représente la concentration comprise entre 0 et 1, qui représente le pourcentage de part de marché
- β_4 représente le log passager, représentant le nombre moyen de passagers

Nos intuitions de départ

- **β_0** : Nous anticipons une valeur positive, même pour des vols très courts, car il y a des charges telles que les salaires et le service en ligne, donc le prix ne peut pas être nul.
- **β_1 et β_2** : Nous supposons que la distance a un impact positif sur le prix, car plus le vol est long, plus la consommation de kérosène est importante ; par conséquent, le prix augmente.
- **β_3** : Nous attendons un signe positif, car plus les parts de marché sont importantes, plus on se rapproche d'une situation de monopole, ce qui implique moins de concurrence, donc la compagnie fixe les prix qu'elle souhaite.
- **β_4** : Nous attendons un signe positif. Car plus il y a de demande sur un billet d'avion plus il sera cher conformément à la loi de l'offre et la demande.

Equation estimée

Via le modèle des MCO notre équation estimée est :

$$\widehat{\log(fare)} = 7,55 - 1,04 \log(dist) + 0,11 (\log(dist))^2 + 0,22 \log(concen) - 0,08 \log(passen)$$

Nous sommes sur le cas d'une régression multiple, il faut bien penser que toute chose est égale par ailleurs. Lorsque la demande diminue de 1%, le prix du billet diminue de 0,08%. C'est le même principe pour la distance : β_1 est négatif, cela peut être surprenant, mais il ne faut pas oublier de prendre également en compte β_2 , qui est positif. Cela nous donne une relation convexe : les prix sont élevés sur une courte distance, puis diminuent ou stagnent sur les distances moyennes. Ensuite, ils remontent sur les longs courriers ; ainsi, la distance reste très significative. Nous avons également la concentration, qui elle est une semi-élasticité, c'est-à-dire que si la part de marché du transporteur augmente de 10 points de pourcentage, alors le prix du billet

augmente de 2,2%. Pour finir, nous allons voir pour la constante β_0 , qui est égal à 7,55 : c'est une relation log-niveau. Pour interpréter cette valeur, il faut la mettre sous forme exponentielle.


$$e^{7,55} \approx 1900$$

Cela signifie que si toutes les variables explicatives sont égales à 0, alors le prix du billet serait 1 900 dollars, ce qui semble irréal car un vol a forcément une distance minimale, on peut plus interpréter cette variable comme un ajustement mathématique plus qu'une valeur économique.

II - Détection de l'hétéroscédasticité dans le modèle

Comme on est dans un modèle à coupe transversale, l'éventualité d'un effet taille peut impacter l'hypothèse H2. Cela signifie que les erreurs ne seraient pas constantes pour toutes les observations.

Figure 3 : graphique des résidus de la régression



En représentant le graphique des résidus de la régression, on remarque une dispersion des erreurs observées. On peut penser à un risque d'hétéroscédasticité. Pour cela, nous réaliserons un test de White.

$$H_0 : \sigma_i^2 = \sigma_u^2 \forall i \text{ vs. } H_1 : \sigma_i^2 \neq \sigma_u^2$$

On teste l'hypothèse nulle (que les variances des erreurs sont les mêmes pour chaque observation $\Rightarrow$ homoscélasticité) contre l'hypothèse alternative H1 (les perturbations sont hétéroscédastiques).

Test de White

Test de White pour l'hétéroscédasticité
MCO, utilisant les observations 1-1149
Variable dépendante: uhat^2

	coefficient	éc. type	t de Student	p. critique	
const	-42,6359	14,0146	-3,042	0,0024	***
ldistsq	2951,50	3031,80	0,9735	0,3305	
concen	0,557519	1,66719	0,3344	0,7381	
lpassen	-0,0738541	0,312356	-0,2364	0,8131	
ldist	26,5184	9,04743	2,931	0,0034	***
sq_ldistsq	-0,0219984	0,00893203	-2,463	0,0139	**
X2_X3	0,0183985	0,0394559	0,4663	0,6411	
X2_X4	0,00236091	0,00711609	0,3318	0,7401	
X2_X5	0,596396	0,228872	2,606	0,0093	***
sq_concen	0,123006	0,118243	1,040	0,2984	
X3_X4	0,0323214	0,0226657	1,426	0,1541	
X3_X5	-0,249964	0,512315	-0,4879	0,6257	
sq_lpassen	-0,00453327	0,00212856	-2,130	0,0334	**
X4_X5	0,00210109	0,0936074	0,02245	0,9821	
sq_ldist	-2957,52	3031,77	-0,9755	0,3295	

R2 non-ajusté = 0,169634

Statistique de test: $TR^2 = 194,909932$,
avec p. critique = $P(\text{Khi-deux}(14) > 194,909932) = 0,000000$

D'après les tests de White réalisés sur Gretl, on a $Q_w = 194,91$, ce qui est largement supérieur à 23,685, la valeur théorique.

Donc, on refuse l'hypothèse nulle et on conclut que les perturbations sont hétéroscédastiques.

Dans la situation où il y a de l'hétéroscédasticité, les écarts-types des estimateurs MCO sont faussés, ce qui impacte la significativité des paramètres et des tests de Student.

Même si notre test de White est concluant, nous réalisons un test de Breusch-Pagan pour confirmer la présence d'hétéroscédasticité. A priori, on devrait bien trouver de l'hétéroscédasticité, car la probabilité de ne pas refuser l'hypothèse nulle tend vers 0.

Test de Breusch-Pagan

Test de Breusch-Pagan pour l'hétéroscédasticité

MCO, utilisant les observations 1-1149

Variable dépendante: uhat^2 standardisé

	coefficient	éc. type	t de Student	p. critique	
const	14,3631	2,64423	5,432	6,81e-08	***
ldistsq	0,272759	0,0604661	4,511	7,12e-06	***
concen	0,894705	0,188075	4,757	2,21e-06	***
lpassen	0,0697887	0,0342317	2,039	0,0417	**
ldist	-3,98329	0,798516	-4,988	7,03e-07	***

Somme des carrés expliquée = 184,696

Statistique de test: LM = 92,348057,

avec p. critique = $P(\text{Khi-deux}(4) > 92,348057) = 0,000000$

La probabilité qu'il y ait de l'homogénéité est nulle. On en conclut que les perturbations sont hétéroscédastiques.

Ce résultat confirme que les écarts-types des estimateurs MCO vont être faussés, ainsi que les tests de Student et donc la significativité globale des paramètres. Afin de « corriger » l'hétéroscédasticité, nous réaliserons un modèle MCO par le biais des écarts-types robustes.

Modèle robuste

Modèle 2: MCO, utilisant les observations 1-1149

Variable dépendante: lfare

Écarts-types robustes (hétéroscédasticité), variante HC1

	coefficient	éc. type	t de Student	p. critique	
const	7,54663	0,912169	8,273	3,59e-016	***
ldistsq	0,108467	0,0202268	5,363	9,92e-08	***
concen	0,215019	0,0602251	3,570	0,0004	***
lpassen	-0,0805355	0,0104169	-7,731	2,32e-014	***
ldist	-1,03732	0,271249	-3,824	0,0001	***

Moyenne var. dép. 5,152683 Éc. type var. dép. 0,417039
Somme carrés résidus 120,4099 Éc. type régression 0,324428
R2 0,396931 R2 ajusté 0,394822
F(4, 1144) 200,2154 P. critique (F) 3,5e-130
Log de vraisemblance -334,4343 Critère d'Akaike 678,8687
Critère de Schwarz 704,1019 Hannan-Quinn 688,3942

Log de vraisemblance pour fare = -6254,87

Nous avons mis en rouge les nouvelles valeurs de la correction de White.

Les estimateurs MCO n'ont pas changé, ainsi nous gardons la même équation estimée. Mais les écarts-types, t de Student et la p critique ont changé pour toutes les variables, ainsi que la valeur de Fisher et sa p critique.

Malgré toutes ces modifications, au seuil de 1%, toutes nos variables restent significatives.

III – Significativité

Modèle 2: MCO, utilisant les observations 1-1149

Variable dépendante: lfare

Écarts-types robustes (hétéroscédasticité), variante HC1

	coefficient	éc. type	t de Student	p. critique	
const	7,54663	0,912169	8,273	3,59e-016	***
ldistsq	0,108467	0,0202268	5,363	9,92e-08	***
concen	0,215019	0,0602251	3,570	0,0004	***
lpassen	-0,0805355	0,0104169	-7,731	2,32e-014	***
ldist	-1,03732	0,271249	-3,824	0,0001	***

Moyenne var. dép. 5,152683 Éc. type var. dép. 0,417039

Somme carrés résidus 120,4099 Éc. type régression 0,324428

R2 0,396931 R2 ajusté 0,394822

F(4, 1144) 200,2154 P. critique (F) 3,5e-130

Log de vraisemblance -334,4343 Critère d'Akaike 678,8687

Critère de Schwarz 704,1019 Hannan-Quinn 688,3942

Log de vraisemblance pour fare = -6254,87

Test de Student

Nous réalisons les tests de Student pour voir si nos variables explicatives sont significatives pour expliquer les prix des billets d'avion. Nous allons réaliser les tests au seuil 1%. Pour cela, nous allons comparer la valeur absolue de la statistique t de Student fournie par Gretl à la valeur qui est dans la table de Student pour 1% : on a 2,5857.

Au seuil 1%, pour β_0 , elle est significative car 8,273 est supérieur à 2,5857, le seuil dans la table de Student à laquelle on le compare. Toutes nos variables sont supérieures à ce stade, donc toutes nos variables sont significatives au seuil 1%.

Test de Fischer

Le test de Fisher permet de mesurer la significativité globale du modèle.

Sur notre Modèle 1, on a $F(4, 1144) = 200,2154$. Dans la table, nous sommes à 4 variables et plus d'infini en n_2 , donc 2,37. Notre F est donc largement supérieur à 2,37 ; notre modèle est plus que significatif.

Qualité d'ajustement du modèle

R^2 est environ égal à 0,4 soit 40%. Cela veut dire que 40% de la variance est expliquée par le modèle. La qualité d'ajustement est donc plutôt correcte pour notre modèle. Mais il faut faire attention : cela ne veut pas dire que notre modèle est sans anormalité.

Point moyen de l'échantillon

	Moyenne	Médiane	E.T.	Min	Max
ldist	6,6965	6,7581	0,65953	4,5539	7,9099
lfare	5,1527	5,1818	0,41704	4,1271	6,2577
ldistsq	45,277	45,672	8,7297	20,738	62,566
concen	0,60157	0,58720	0,19702	0,17970	1,0000
lpassen	6,0599	5,9349	0,91666	0,69315	9,0475

Au point moyen de l'échantillon, la valeur prédite du logarithme du prix est de 5.1527, ce qui nous correspond à un prix moyen estimé de 172.90 dollars.

IV - Hypothèses potentiellement non respectées

Hypothèse H3 : absence d'erreur de mesure

En effet, cette variable peut être mal mesurée si le trajet contient une escale. Mais aussi, lors d'un vol, l'avion ne va pas en ligne droite, donc pour un même trajet, la distance n'est pas forcément la même au mile près. De plus, la variable des passagers est une moyenne annuelle : elle ne prend pas en compte les saisons ni les périodes de vacances. Ces imprécisions peuvent introduire un biais dans les estimateurs.

Hypothèse H5 : absence de multi colinéarité

Les variables $\log(\text{distance})$ et $\log(\text{distance})^2$ sont naturellement très corrélées, ce qui peut engendrer une augmentation de la variance des estimateurs. Mais aussi, $\log(\text{passagers})$ peut avoir un lien avec la distance. En effet, le modèle gravitaire prévoit une baisse de passagers plus la distance augmente. Les longs courriers essayent de compenser cette perte via les correspondances. Même si tous nos tests nous ont montré que nos variables étaient significatives, cette corrélation peut limiter la précision de l'interprétation des coefficients.

Hypothèse

Cette hypothèse a déjà été rejetée quand nous avons montré qu'il y ait de l'hétéroscédasticité dans notre modèle.

H2 :

V - Limite de la base de données

Notre base de données est assez complète, mais elle n'explique que 40% de la variance des prix. Donc, une part importante du prix des billets nous échappe et montre certaines limites dans la base de données.

L'absence de la date de réservation.

En effet, nous pensons que cela peut avoir un impact majeur sur le prix. Il est bien connu que prendre ces billets d'avion des mois à l'avance permet des économies importantes : les prix peuvent être multipliés par 5 parfois si l'on prend le billet la veille du départ.

L'absence de distinction de classe et qualité du service

La variable fare est une moyenne des prix des billets d'avion, mais elle ne précise pas si c'est un voyage première classe, Business ou économique. De plus, le modèle ne distingue pas les compagnies aux États-Unis : nous pouvons retrouver la compagnie Southwest, qui est dite plus low-cost que Delta ou United, du fait qu'elle ne propose pas les mêmes services comme les repas, le bagage inclus dans le billet ou même juste le confort des places. Ces variables ont aussi un impact sur les prix des billets.

Coûts aéroportuaires et créneaux horaires.

Notre modèle prend en compte la distance, le carburant, mais ignore les coûts des aéroports. Prendre un vol qui atterrit à New York ou Chicago et dans les villes principales du pays coûte plus cher qu'atterrir dans les villes secondaires. Mais aussi, les prix des vols varient en fonction des heures d'arrivée et de départ : en général, les vols du matin ou du soir sont plus chers que ceux en milieu de journée.

VI – Conclusion

Pour conclure, notre rapport visait à identifier les variables expliquant le prix des billets d'avion. À partir de la base AIRFARE, appliquée uniquement à l'année 2000 afin d'obtenir une coupe transversale, nous avons estimé un modèle Log-Log. Les résultats montrent que la distance, la concentration du marché et le nombre de passagers influencent significativement les tarifs : la relation entre distance et prix est convexe, la concentration tend à augmenter les prix, tandis qu'une demande plus élevée les réduit. L'ensemble des coefficients est significatif au seuil de 1 %, confirmant leur rôle explicatif, et le modèle permet d'expliquer environ 40 % de la variance des prix. Les tests statistiques valident globalement la qualité du modèle, mais révèlent la présence d'hétéroscédasticité via les tests de White et Breusch–Pagan, ce qui a justifié l'utilisation d'erreurs robustes. Malgré cette limite, les résultats obtenus restent cohérents avec les mécanismes économiques du secteur aérien et permettent de mieux comprendre les déterminants des tarifs.

VII - Bibliographie

Borenstein, S. (1989). *Hubs and high fares: Dominance and market power in the US airline industry*. (Un classique de l'économie du transport).

- Williams, K. R. (2022). *Dynamic airline pricing and seat availability*.
- ATA (International Air Transport Association). (2019). *Airport Charges and Peak Pricing*.